

Trabalho Intermediário: Agrupamento e Sistemas Fuzzy

1st Guilherme Alvarenga de Azevedo
Departamento de Computação
CEFET-MG
Divinópolis, Brasil
guilherme@aluno.cefetmg.br

2nd Maria Eduarda Teixeira Souza
Departamento de Computação
CEFET-MG
Divinópolis, Brasil
maria@aluno.cefetmg.br

Resumo—Sistemas de classificação baseados em aprendizado de máquina frequentemente enfrentam o compromisso entre precisão e explicabilidade. Modelos de inferência fuzzy, em especial a arquitetura de Takagi-Sugeno (TS) [3], emergem como uma solução interessante ao combinar a capacidade de adaptação aos dados com a transparência das regras lógicas. Este artigo propõe e avalia um sistema de classificação fuzzy guiado pelo algoritmo de agrupamento *Fuzzy C-Means* (FCM) [2]. Para evidenciar o impacto da qualidade dos dados nas fronteiras de decisão do modelo, o estudo realiza uma análise comparativa visual e métrica entre dois cenários: um modelo base (com dados brutos) e um modelo otimizado (com remoção de atributos correlacionados e balanceamento da base via SMOTE-ENN [4]). Os resultados demonstraram que a configuração otimizada superou expressivamente o cenário base, reduzindo a sobreposição entre as classes e elevando a acurácia de 62,23% para 82,87%, com a curva AUC saltando de 0,811 para 0,942.

Index Terms—Sistema Takagi-Sugeno, Fuzzy C-Means, Classificação Multiclasse, SMOTE-ENN, Análise Comparativa.

I. INTRODUÇÃO

A crescente complexidade dos problemas de reconhecimento de padrões tem impulsionado o desenvolvimento de modelos preditivos cada vez mais avançados. Contudo, muitas arquiteturas funcionam como caixas-pretas (*black-boxes*), dificultando o entendimento das suas decisões [6]. Em áreas onde explicar o resultado é tão importante quanto acertá-lo, os Sistemas de Inferência Fuzzy destacam-se por criar regras claras do tipo SE-ENTÃO [7].

A arquitetura de Takagi-Sugeno (TS) [3] apresenta vantagens práticas em tarefas de aprendizado supervisionado, pois utiliza equações matemáticas simples para gerar suas saídas, garantindo eficiência no processamento pelo computador [8].

O sucesso desses sistemas depende diretamente de como os dados de entrada são divididos e agrupados. Para realizar essa divisão de forma inteligente, o algoritmo de agrupamento *Fuzzy C-Means* (FCM) [2] provou-se muito eficaz, permitindo mapear o comportamento dos dados e criar as regras do sistema automaticamente [9].

No entanto, bases de dados reais frequentemente sofrem com o desbalanceamento (muitos exemplos de uma classe e poucos de outra), atributos repetitivos (multicolinearidade) e muita sobreposição nas regiões de decisão, o que confunde o modelo fuzzy.

Diante desse cenário, este artigo propõe o desenvolvimento de um classificador fuzzy com foco em uma análise comparativa. O objetivo é avaliar o comportamento interno (formação de regras) e externo (taxa de acerto e agrupamento) de um cenário base (dados originais padronizados) contra um cenário otimizado (dados filtrados e balanceados com o método SMOTE-ENN [4]).

O restante deste trabalho está estruturado da seguinte forma: a Seção II descreve a base de dados. A Seção III aborda a análise exploratória. A Seção IV explica o algoritmo FCM e a Seção V o modelo Takagi-Sugeno. A Seção VI relata a implementação. A Seção VII compara as imagens e resultados dos dois cenários, seguida da conclusão na Seção VIII.

II. DESCRIÇÃO DO CONJUNTO DE DADOS

A base de dados utilizada é sintética e conta com 10.000 registros, 6 características numéricas (*atributo_1* a *atributo_6*) e um rótulo alvo com quatro categorias (classes) diferentes.

A. Pré-processamento dos Dados

Um fluxo de limpeza e preparação foi aplicado, dividindo-se em dois caminhos para a nossa comparação:

- 1) **Limpeza e Normalização (Ambos os cenários):** Remoção de 4 linhas duplicadas e 90 valores vazios (restando 9.910 amostras), seguida da padronização estatística (*Z-score*), que coloca todos os valores na mesma escala:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

- 2) **Filtro de Correlação (Apenas Cenário Otimizado):** Variáveis com uma similaridade maior que 0,8 foram removidas para evitar o excesso de informações repetidas.
- 3) **SMOTE-ENN [4] (Apenas Cenário Otimizado):** Técnica que cria dados artificiais para as classes que têm poucas amostras e, ao mesmo tempo, apaga amostras que estão "invadindo" o espaço das outras classes, limpando as fronteiras de decisão (reduzindo a base para 4.055 amostras focadas e claras).

III. ANÁLISE EXPLORATÓRIA E MULTICOLINEARIDADE

A análise exploratória inicial revelou um grande desequilíbrio: as Classes 1, 3 e 4 tinham, cada uma, cerca de 30% do total de dados, enquanto a Classe 2 era a minoria isolada, com apenas 10%. Além disso, o atributo_1 apresentava forte semelhança com quase todos os outros atributos.

Tabela I
ATRIBUTOS ALTAMENTE DEPENDENTES DO ATRIBUTO 1 ($r > 0,8$)

Atributo A	Atributo B	Correlação (r)
atributo_1	atributo_3	+0,9070
atributo_1	atributo_2	+0,8985
atributo_1	atributo_6	+0,8880
atributo_1	atributo_4	+0,8211

A Tabela I mostra que esses dados são redundantes. No Cenário Base, nós mantemos todas essas colunas, forçando o sistema a lidar com a repetição. Já no Cenário Otimizado, nós retiramos os atributos 2, 3, 4 e 6, facilitando o trabalho matemático do modelo.

IV. METODOLOGIA DE AGRUPAMENTO FUZZY

O algoritmo *Fuzzy C-Means* (FCM) [2] divide os dados em grupos (C), mas com a vantagem de que um único dado pode pertencer parcialmente a vários grupos ao mesmo tempo. O parâmetro $m > 1$ controla o quanto esses grupos podem se misturar.

O processo funciona repetindo dois passos: calcular a posição do centro de cada grupo e calcular o grau de pertencimento dos dados a esses centros:

$$v_j = \frac{\sum_{i=1}^N u_{ij}^m x_i}{\sum_{i=1}^N u_{ij}^m} \quad (2)$$

$$u_{ij} = \left[\sum_{k=1}^C \left(\frac{\|x_i - v_j\|}{\|x_i - v_k\|} \right)^{\frac{2}{m-1}} \right]^{-1} \quad (3)$$

O número de centros foi definido como $C = 4$ (para representar as quatro classes). Após estabilizar, os dados dos grupos são usados para criar o formato do modelo preditivo.

V. MODELAGEM DO SISTEMA FUZZY TAKAGI-SUGENO

O sistema utiliza a arquitetura Takagi-Sugeno [3]. Com base nos grupos encontrados pelo FCM, ele cria regras do tipo:

SE x_1 pertence ao grupo 1 E x_2 pertence ao grupo 1
ENTÃO A previsão é calculada por uma equação ($y = p_0 + p_1x_1 + p_2x_2$)

As regras utilizam curvas gaussianas (em formato de sino) para definir as áreas de atuação:

$$\mu_{id}(x_d) = \exp \left(-\frac{(x_d - v_{id})^2}{2\sigma_{id}^2} \right) \quad (4)$$

A classe final escolhida pelo sistema é aquela que tiver a maior pontuação na soma ponderada das regras:

$$\hat{y}_k(x) = \sum_{i=1}^R \bar{w}_i(x) y_{ik}(x) \quad (5)$$

Os cálculos para encontrar os melhores valores das equações são feitos por um método seguro chamado Mínimos Quadrados Ponderados.

VI. DESCRIÇÃO DA IMPLEMENTAÇÃO

O projeto foi todo escrito em linguagem Python 3, usando a biblioteca *NumPy* para fazer a matemática do sistema fuzzy funcionar do zero. A avaliação do modelo separou 80% dos dados para treino e 20% para teste (*Holdout*). O código gera automaticamente gráficos que nos permitem comparar como as regras agem com os dados brutos e com os dados otimizados. O código fonte está disponível em [1].

VII. RESULTADOS E DISCUSSÃO COMPARATIVA

Esta seção compara o desempenho do modelo nos dois cenários avaliados. O cenário base apresentou acurácia geral de 62,23%. Em nítido contraste, o cenário otimizado alcançou 82,87% de acurácia, comprovando que limpar e organizar os dados antes do treino é essencial para a eficiência das regras fuzzy.

A. Análise de Sensibilidade do Expoente de Fuzzificação

As Figuras 1 e 2 mostram como o modelo se comporta quando alteramos o parâmetro de mistura m .




Figura 1. Variação das métricas de desempenho em função do expoente de fuzzificação m no cenário base. Observa-se perda gradual de desempenho para valores elevados de m , indicando maior dificuldade do modelo em definir fronteiras de decisão consistentes.




Figura 2. Variação das métricas de desempenho em função do expoente de fuzzificação m no cenário otimizado. O pré-processamento com remoção de correlação e SMOTE-ENN resultou em comportamento mais estável e menos sensível às variações de m .

Com os dados brutos, o aumento da flexibilidade faz o modelo se perder rapidamente. Já com os dados limpos pelo SMOTE-ENN, as classes estão bem separadas, permitindo que o sistema seja muito mais tolerante a ajustes.

B. Formato das Regras (Funções de Pertinência)

As Figuras 3 e 4 ilustram as curvas que definem como as regras enxergam as informações.

A tentativa de usar atributos repetidos faz com que as curvas fiquem muito amontoadas (Cenário Base). Ao remover os excessos, o sistema consegue criar regras claras e fáceis de interpretar (Cenário Otimizado).

C. Dispersão Espacial: Valores Reais vs. Preditos

Para entender visualmente como o modelo divide o espaço, as Figuras 5 e 6 comparam os agrupamentos reais com as decisões tomadas pelo modelo.

No cenário base, a enorme nuvem de pontos agrupados causa imprecisão nas bordas. Ao visualizar o cenário otimizado, percebe-se claramente a ação de "limpeza" do método ENN, que apaga os pontos rebeldes que se infiltram em áreas erradas, facilitando o posicionamento dos quatro centros (marcados em "X") pelo algoritmo fuzzy.

D. Matrizes de Confusão e o Problema das Classes

Como visto na análise exploratória, a base tinha um forte desequilíbrio na Classe 2. O reflexo disso e da posterior otimização está claro nas Figuras 7 e 8.

Antes do pré-processamento (Cenário Base), a Classe 2 era a menor e a mais prejudicada, sofrendo enormes taxas de erro porque "sumia" no meio das classes maiores. Após a otimização com o SMOTE, a identificação da Classe 2 subiu de forma espetacular. Porém, a dificuldade do modelo mudou de foco: a Classe 3 tornou-se o novo gargalo, apresentando agora a maior taxa de confusão entre as categorias.

E. Análise das Curvas ROC

Por fim, as Curvas ROC medem a confiança matemática do sistema em separar as classes positivamente (Figuras 9 e 10).

O salto na métrica AUC consolida a premissa de que sistemas fuzzy funcionam consideravelmente melhor em ambientes com menos variáveis repetidas e com dados bem distribuídos.

F. Síntese dos Resultados Experimentais

Para consolidar a análise comparativa e detalhar o impacto individual de cada técnica aplicada, a Tabela II apresenta uma visão geral das métricas para oito configurações experimentais. Além do foco central deste estudo — que contrasta o cenário base puro com o cenário totalmente otimizado —, foram avaliadas combinações intermediárias (apenas limpeza ou apenas balanceamento) e a aplicação da validação cruzada (K-Fold) em contraponto ao método Holdout tradicional.

Como evidenciado na Tabela II, a aplicação isolada da remoção de correlação não traz ganhos significativos sem o tratamento do desbalanceamento de classes, resultando em métricas quase idênticas ao cenário base. Por outro lado, a introdução do SMOTE-ENN atua como o principal motor

para o salto de desempenho do sistema de inferência fuzzy. A configuração ótima confirmou-se na utilização simultânea do SMOTE-ENN com a filtragem de variáveis sob o método Holdout, garantindo os maiores índices de acurácia (0,8287) e AUC (0,9417).

Por fim, a validação K-Fold corroborou as tendências observadas no Holdout. A estabilidade das métricas entre as partições atesta que os ganhos obtidos não são frutos de um viés na divisão aleatória dos dados, mas sim da melhor separabilidade espacial proporcionada pelo pré-processamento.

Tabela II
RESULTADOS CONSOLIDADOS DAS OITO CONFIGURAÇÕES
EXPERIMENTAIS

SMOTE	Validação	Rem. Corr.	Acurácia	Ac. Macro	Revocação	AUC	F1-Score
Não	Holdout	Não	0,6223	0,5184	0,6223	0,8114	0,5894
Não	K-Fold	Não	0,6329	0,5277	0,6329	0,8202	0,5999
Não	Holdout	Sim	0,6188	0,5163	0,6188	0,8140	0,5800
Não	K-Fold	Sim	0,6240	0,5206	0,6240	0,8181	0,5852
Sim	Holdout	Não	0,8126	0,6545	0,8126	0,9271	0,7898
Sim	K-Fold	Não	0,8153	0,6577	0,8153	0,9292	0,7936
Sim	Holdout	Sim	0,8287	0,6777	0,8287	0,9417	0,7999
Sim	K-Fold	Sim	0,8166	0,6672	0,8166	0,9417	0,7883

VIII. CONCLUSÃO

Este trabalho remodelou e comparou um sistema de classificação Takagi-Sugeno [3] para provar como a qualidade dos dados afeta severamente o desempenho das regras fuzzy [2].

Ficou claro que o motor matemático do modelo sofre na presença de repetições (correlação) e desbalanceamento. Ao utilizar o SMOTE-ENN [4] junto à filtragem de atributos, o sistema operou com muito mais estabilidade, saltando de 62,23% de acerto para 82,87%. A comparação visual pelas imagens confirmou que o modelo otimizado gerou regras mais lógicas, agrupamentos mais nítidos e curvas ROC mais fortes.

A análise mais importante dos testes revelou uma troca curiosa de vulnerabilidades: a Classe 2, que era originalmente o maior fracasso do modelo por possuir poucas amostras, foi solucionada pelo SMOTE-ENN. Contudo, essa intervenção transferiu a dificuldade do modelo para a Classe 3, que se tornou a nova região de confusão da base.

Como melhorias futuras, sugere-se a investigação de novas formas geométricas para os grupos (distância de Mahalanobis) a fim de tentar resolver a dificuldade residual envolvendo a Classe 3, além de testes em bancos de dados reais.

REFERÊNCIAS

- [1] G. A. Azevedo and M. E. T. Souza, "CLUSTERING-FUZZY-SYSTEM-IC: Atividade Prática 01," 2026. [Online]. Disponível em: <https://github.com/alvarengazv/clustering-fuzzy-system-ic>.
- [2] J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*. New York: Plenum Press, 1981.
- [3] T. Takagi and M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-15, no. 1, pp. 116–132, 1985.
- [4] G. E. A. P. A. Batista, R. C. Prati, and M. C. Monard, "A study of the behavior of several methods for balancing machine learning training data," *ACM SIGKDD Explorations Newsletter*, vol. 6, no. 1, pp. 20–29, 2004.
- [5] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.

- [6] A. M. Silva, “Inteligência Computacional: Notas de Aula 05 — Fuzzy Introdução,” Notas de Aula, 2026.
- [7] A. M. Silva, “Inteligência Computacional: Notas de Aula 06 — Fuzzy Conjuntos,” Notas de Aula, 2026.
- [8] A. M. Silva, “Inteligência Computacional: Notas de Aula 08 — Fuzzy Inferência 01,” Notas de Aula, 2026.
- [9] A. M. Silva, “Inteligência Computacional: Notas de Aula 10 — Agrupamento,” Notas de Aula, 2026.

Funções de Pertinência Gaussianas (derivadas do FCM)




Figura 3. Funções de pertinência geradas no cenário base. Observa-se elevada sobreposição entre curvas associadas aos atributos.

Funções de Pertinência Gaussianas (derivadas do FCM)




Figura 4. Funções de pertinência geradas no cenário otimizado. A redução de atributos correlacionados resultou em curvas com menor sobreposição entre regiões fuzzy.

Comparação: Classes Reais vs Preditas




Figura 5. Distribuição espacial das amostras no cenário base. Observa-se maior sobreposição entre classes e regiões de transição menos definidas.

Comparação: Classes Reais vs Preditas




Figura 6. Distribuição espacial das amostras no cenário otimizado. O pré-processamento reduziu a sobreposição entre agrupamentos e favoreceu a separação entre classes.




Figura 7. Matriz de confusão do cenário base. Observa-se elevada taxa de erro, principalmente associada à Classe 2.




Figura 8. Matriz de confusão do cenário otimizado. Observa-se redução significativa dos erros de classificação após o balanceamento da base.




Figura 10. Curvas ROC do cenário otimizado, com AUC igual a 0,942, evidenciando elevada capacidade discriminativa do modelo.




Figura 9. Curvas ROC do cenário base, com AUC igual a 0,811, indicando capacidade moderada de separação entre classes.