



Trabalho Intermediário: Agrupamento e Sistemas Fuzzy

Análise Comparativa Baseada no Modelo Takagi-Sugeno

Guilherme Alvarenga de Azevedo
Maria Eduarda Teixeira Souza

CEFET-MG

2026

O Dilema dos Modelos de Aprendizado:

- Modelos complexos frequentemente agem como **caixas-pretas**, impossibilitando entender o porquê de uma decisão.
- **Sistemas de Inferência Fuzzy**: Unem a precisão matemática com a transparência de regras linguísticas legíveis do tipo *SE-ENTÃO*.

Objetivo do Trabalho:

- Desenvolver um classificador baseado na arquitetura **Takagi-Sugeno (TS)** de primeira ordem.
- Avaliar visualmente e numericamente o impacto do tratamento dos dados comparando um **Cenário Base** contra um **Cenário Otimizado**.

Caracterização Geral da Base Sintética

Estrutura dos Dados:

- **Volume:** 10.000 instâncias originais.
- **Atributos:** 6 variáveis preditoras numéricas (*atributo_1* a *atributo_6*).
- **Alvo:** 4 classes distintas.

Distribuição Original das Classes

Classe	Amostras	Proporção
Classe 1	3.000	30,0%
Classe 2	1.000	10,0%
Classe 3	3.000	30,0%
Classe 4	3.000	30,0%

Desbalanceamento Inicial

A **Classe 2** é a minoria isolada na base bruta (apenas 10% das amostras), gerando um desafio realista.

Estratégia de Bifurcação e Limpeza

- **Ambos os Cenários:** Remoção de 4 duplicatas, 90 valores nulos e aplicação de normalização *Z-score*.

Cenário Base

Utiliza os dados brutos e mantém todas as 6 características preditoras, delegando as inconsistências diretamente ao modelo.

Cenário Otimizado

Aplica **Filtro de Correlação** (remoção de variáveis repetidas) e tratamento híbrido **SMOTE-ENN** (balanceamento e limpeza de fronteiras).

Visualização da Limpeza de Fronteiras

Comparação: Antes e Depois da aplicação do SMOTE-ENN




Figura: Limpeza de fronteiras gerada pelo SMOTE-ENN (4.055 amostras finais).

O Problema da Multicolinearidade

Redundância Informacional Detectada:

- A matriz de Pearson revelou que o atributo_1 possui forte dependência linear com quase todas as outras variáveis da base.

Atributo A	Atributo B	Coeficiente de Pearson (r)
atributo_1	atributo_3	+0,9070
atributo_1	atributo_2	+0,8985
atributo_1	atributo_6	+0,8880
atributo_1	atributo_4	+0,8211

Ação no Cenário Otimizado

Exclusão completa dos atributos 2, 3, 4 e 6. O modelo passa a trabalhar apenas com eixos independentes, simplificando as regras.

Agrupamento via Fuzzy C-Means (FCM)

- Permite que cada amostra pertença parcialmente a múltiplos grupos ao mesmo tempo através de graus de pertinência contínuos $u_{ij} \in [0, 1]$.
- Define a geometria das regras gaussianas (centros v_j e dispersão σ).

Atualização dos Centros

$$v_j = \frac{\sum_{i=1}^N u_{ij}^m x_i}{\sum_{i=1}^N u_{ij}^m}$$

Atualização das Pertinências

$$u_{ij} = \left[\sum_{k=1}^C \left(\frac{\|x_i - v_j\|}{\|x_i - v_k\|} \right)^{\frac{2}{m-1}} \right]^{-1}$$

- O número de grupos foi fixado em $C = 4$. O critério de parada adotou tolerância de $\epsilon = 10^{-6}$.

O Motor de Inferência Takagi-Sugeno (TS)

Estrutura de Regras de Primeira Ordem:

- **SE** x_1 é A_{i1} E ... E x_D é A_{iD} **ENTÃO** $y_{ik} = p_{ik0} + \sum_{d=1}^D p_{ikd}x_d$

Ajuste Matemático Local:

- Os antecedentes usam curvas gaussianas baseadas nos eixos extraídos.
- Os parâmetros lineares do consequente são estimados localmente por **Mínimos Quadrados Ponderados (WLS)**, onde os pesos são dados pelas forças de ativação das regras.
- A resolução numérica utiliza a **Decomposição em Valores Singulares (SVD)**, que impede o colapso dos cálculos diante de correlações residuais.

Análise de Sensibilidade do Expoente m

Cenário Base

Comparação Consolidada (Holdout 80/20)

Comparação de Métricas vs Expoente m (n_rules=4)




Figura: Cenário base. Observa-se perda gradual de desempenho para valores elevados de m , indicando maior dificuldade do modelo em definir fronteiras de decisão consistentes.

Cenário Otimizado

Comparação Consolidada (Holdout 80/20)

Comparação de Métricas vs Expoente m (n_rules=4)





Figura: Cenário otimizado. O pré-processamento com remoção de correlação e SMOTE-ENN resultou em comportamento mais estável e menos sensível às variações de m .

Formato das Regras (Cenário Base)

Cenário Base (6 Atributos)



Funções de Pertinência Gaussianas (derivadas do FCM)



Formato das Regras (Cenário Otimizado)

Cenário Otimizado (Atributos Filtrados)

Funções de Pertinência Gaussianas (derivadas do FCM)



Regras bem espaçadas, nítidas e semanticamente fáceis de interpretar.

Dispersão Espacial: Cenário Base

Valores Reais vs. Preditos

Comparação: Classes Reais vs Preditas




Figura: Distribuição espacial das amostras no cenário base. Observa-se maior sobreposição entre classes e regiões de transição menos definidas.

Dispersão Espacial: Cenário Otimizado

Valores Reais vs. Preditos (Refinado)





Figura: Distribuição espacial das amostras no cenário otimizado. O pré-processamento reduziu a sobreposição entre agrupamentos e favoreceu a separação entre classes.


Matrizes de Confusão: Cenário Base

Cenário Base




Matrizes de Confusão: Cenário Otimizado

Cenário Otimizado



Análise das Curvas ROC (Cenário Base)

Por fim, as Curvas ROC medem a confiança matemática do sistema em separar as classes positivamente (Figuras 8 e 9).



Análise das Curvas ROC (Cenário Otimizado)




Figura: Curvas ROC do cenário otimizado, com AUC igual a 0,942, evidenciando elevada capacidade discriminativa do modelo.

Síntese de Métricas Globais

Comparativo de Desempenho: Cenário Base vs. Otimizado

SMOTE-ENN	Validação	Rem. Corr.	Acurácia	Ac. Macro	Revocação	AUC	F1-Score
Não	Holdout	Não	0,6223	0,5184	0,6223	0,8114	0,5894
Não	K-Fold	Não	0,6329	0,5277	0,6329	0,8202	0,5999
Não	Holdout	Sim	0,6188	0,5163	0,6188	0,8140	0,5800
Não	K-Fold	Sim	0,6240	0,5206	0,6240	0,8181	0,5852
Sim	Holdout	Não	0,8126	0,6545	0,8126	0,9271	0,7898
Sim	K-Fold	Não	0,8153	0,6577	0,8153	0,9292	0,7936
Sim	Holdout	Sim	0,8287	0,6777	0,8287	0,9417	0,7999
Sim	K-Fold	Sim	0,8166	0,6672	0,8166	0,9417	0,7883

Conclusões e Aprendizados

- **Impacto do Pré-processamento:** A união do SMOTE-ENN com a filtragem de atributos correlacionados aliviou o modelo, resultando em um ganho superior a **20 pontos percentuais** na acurácia.
- **Interpretabilidade Preservada:** A remoção de colinearidade gerou funções de pertinência gaussianas limpas e regras semanticamente distinguíveis.
- **A Dinâmica do Erro:** A otimização resolveu com sucesso o problema da Classe 2 (antiga minoria), contudo deslocou o novo foco de erro e confusão para a Classe 3.

Trabalhos Futuros

Investigar algoritmos baseados na distância de Mahalanobis (como Gustafson-Kessel) para mapear grupos elipsoidais e tentar mitigar o erro residual da Classe 3.

Referências Bibliográficas I

- ① AZEVEDO, G. A.; SOUZA, M. E. T. **CLUSTERING-FUZZY-SYSTEM-IC:** Atividade Prática 01. 2026. Disponível em:
<https://github.com/alvarengazv/clustering-fuzzy-system-ic>.
- ② BEZDEK, J. C. *Pattern Recognition with Fuzzy Objective Function Algorithms*. New York: Plenum Press, 1981.
- ③ TAKAGI, T.; SUGENO, M. Fuzzy identification of systems and its applications to modeling and control. *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-15, no. 1, pp. 116-132, 1985.
- ④ BATISTA, G. E. A. P. A.; PRATI, R. C.; MONARD, M. C. A study of the behavior of several methods for balancing machine learning training data. *ACM SIGKDD Explorations Newsletter*, vol. 6, no. 1, pp. 20-29, 2004.
- ⑤ SILVA, A. M. **Inteligência Computacional:** Notas de Aula 08 — Fuzzy Inferência 01 e Notas de Aula 10 — Agrupamento. 2026.

Dúvidas?



Muito obrigado!

`guilherme@aluno.cefetmg.br`

`maria@aluno.cefetmg.br`